

Paper 2 簡單解釋：便宜拆解，昂貴執行

一句話版本

AI 客服代理失敗時，問題出在「規劃」還是「執行」？答案是規劃——但目前的自動規劃器還不夠好。

比喻

想像一個客服代理要處理這個請求：

「我要退那雙鞋、換一頂安全帽、然後把地址改成新的」

這其實是 三件事。如果代理一開始就知道有三件事要做，表現會好很多。但如果它只看到一句話就直接衝去做，很容易漏掉或搞錯。

我們想知道：如果事先幫代理列一張清單（「第一步退鞋、第二步換帽、第三步改地址」），它會不會做得更好？

五種實驗條件

條件	怎麼做	結果
基線	不給清單，直接做	34.8% 通過率
規則式	用正則表達式自動列清單	33.3%（沒用）
Oracle	人類寫的完美清單	57.6% (+22.7pp)
Tiny-LM	讓便宜 AI (Haiku) 寫清單	36.4%（幾乎沒用）
同模型	讓同一個 AI (gpt-4o) 寫清單	34.8%（完全沒用）

核心發現

1. 規劃很重要 — 有了完美清單，通過率從 35% 跳到 58% (+22.7pp)
2. 但自動清單不夠好 — 不管是便宜還是貴的 AI，自動寫的清單都幾乎沒幫助
3. 不是模型太笨 — 用最貴的 gpt-4o 來寫清單也沒用（同模型消融），所以問題不在模型能力
4. 問題在資訊不足 — 光看使用者的第一句話，AI 只能猜到一半的子任務。很多資訊要到對話後面才會出現
5. 成本超低 — 拆解器只花執行器成本的 0.12%，成本不是瓶頸，品質才是

22.7pp 的差距代表什麼？

這個數字叫規劃品質差距（Planning Quality Gap）。它告訴我們：

- 如果有人能造出一個跟人類一樣好的自動拆解器，AI 客服的可靠性可以大幅提升
- 但目前的拆解器（不管大小模型）都只能從第一句話抓到 50% 的必要資訊
- 要彌合這個差距，需要讓拆解器看到更多上下文（多回合對話、查資料庫、領域知識）

這就是未來研究的方向。

這跟 Paper 1 的關係

Paper 1 說：單回路路由不需要每次都用 LLM，便宜的文字比對就能處理 74% 的查詢。

Paper 2 把同樣的想法搬到多回合規劃：能不能用便宜模型做規劃、貴模型做執行？結論是概念可行（oracle +22.7pp），但自動化的品質還不夠。

兩篇共享的核心思想：為每個子任務選對大小的模型（cost-aware）。

數字速記

- 基準測試：τ-bench（22 個複雜零售任務，3 個種子）
- Oracle 提升：+22.7pp（OR=3.5, p=0.007）
- 自動規劃器提升：+0—1.5pp（不顯著）
- 失敗分析：215 筆失敗軌跡，7 類分類法
- 總實驗成本：~\$180
- 程式碼：<https://github.com/drewOrc/tau-bench-decomposition>